

# Capitolul 2. Studiu de caz

## 2.1. Introducere

Analiza imaginilor medicale a devenit o componentă esențială în diagnosticarea și tratamentul multor afecțiuni, iar utilizarea metodelor de învățare profundă (deep learning) a deschis noi oportunități pentru automatizarea și optimizarea acestui proces. În acest context, studiile care explorează performanța modelelor de învățare automată pe imagini radiologice sunt de o importanță majoră. Acest studiu se concentrează pe utilizarea unui subset de 2000 de imagini din setul de date ChestX-ray14 și aplicarea modelului pre-antrenat ResNet50 pentru clasificarea afecțiunilor pulmonare.

Setul de date ChestX-ray14, publicat de Institutul Național al Sănătății (NIH), este unul dintre cele mai mari și cuprinzătoare resurse disponibile pentru cercetarea radiologică. Acesta include peste 100.000 de imagini radiografice ale pieptului, etichetate cu 14 afecțiuni comune, cum ar fi pneumonia, efuziunea pleurală și nodulii pulmonari. Datorită complexității datelor și a etichetării lor precise, acest set este ideal pentru antrenarea și evaluarea modelelor de învățare profundă.

În cadrul acestui studiu, modelul ResNet50, un arhitectură consacrată de rețea neuronală convoluțională, a fost utilizat ca bază pentru clasificarea radiografiilor. ResNet50 este cunoscut pentru utilizarea straturilor reziduale care permit antrenarea rețelelor mai adânci fără riscul de degradare a performanței. Acest model a fost pre-antrenat pe setul de date ImageNet, care include milioane de imagini din domeniul general, fiind astfel capabil să învețe caracteristici vizuale complexe ce pot fi transferate și aplicate pe imagini medicale.

Obiectivul principal al acestui studiu este de a evalua performanța modelului ResNet50 pe un subset de 2000 de imagini selectate din ChestX-ray14, cu accent pe detectarea unor afecțiuni specifice. Studiul explorează, de asemenea, efectele transferului de învățare, optimizarea hiperparametrilor și impactul preprocesării imaginilor asupra acurateței clasificării.

Prin acest demers, dorim să evidențiem potențialul utilizării metodelor de învățare profundă în radiologie și să oferim o bază pentru viitoare cercetări care vizează integrarea inteligenței artificiale în sistemele clinice de diagnosticare.

## 2.2. Utilizarea datelor și a modelului

### 2.2.1 Preprocesarea datelor

Preprocesarea imaginilor este un pas fundamental în realizarea de modele robuste de învățare automată, ajutând la îmbunătățirea calității datelor utilizate pentru antrenare. Acest proces implică mai multe tehnici, esențiale pentru optimizarea datelor de intrare ale modelului ResNet50, următoarele fiind practicate frecvent:

- Normalizarea intensității pixelilor între 0 și 1: Această etapă transformă valorile pixelilor, care inițial se încadrează între 0 și 255, într-un interval mai mic, facilitând o mai bună convergență în timpul antrenamentului modelului. Normalizarea ajută la stabilizarea procesului de învățare, evitând probleme precum dispariția sau explozia gradientului, care pot duce la o performanță suboptimală a rețelei neuronale.
- Redimensionarea imaginilor la 224x224 pixeli: ResNet50 necesită dimensiuni standardizate ale imaginilor pentru a funcționa corect, iar redimensionarea imaginilor asigură uniformitatea necesară, prevenind astfel erorile în procesul de predicție. Redimensionarea imaginii la 224x224 pixeli permite modelului să extragă caracteristici relevante din imagini, păstrând totodată detaliile importante care influențează rezultatele finale.
- Aplicarea unui filtru alb-negru: Transformarea imaginilor color în alb-negru (grayscale) contribuie la simplificarea datelor de intrare și la reducerea dimensiunii informațiilor procesate. Această tehnică poate facilita extragerea caracteristicilor esențiale, îmbunătățind acuratețea predicției, întrucât permite modelului să se concentreze pe geometria și contrastul imaginilor, în loc de detaliile de culoare.
- Reducerea zgomotului: Zgomotul în imagini poate afecta grav performanța modelului AI. Tehnicile de reducere a zgomotului, cum ar fi filtrarea spațială sau transformările în domeniul frecvenței, sunt aplicate pentru a îmbunătăți claritatea imaginilor și a elimina artefactele nedorite care ar putea influența învățarea modelului. Astfel, prin utilizarea unei combinații de metode de prelucrare a imaginilor, se realizează o îmbunătățire semnificativă a calității datelor, ceea ce se traduce în o performanță mai bună a modelului în sarcini de diagnosticare imagistică.

Aceste tehnici nu doar că optimizează seturile de date pentru utilizarea în modelele AI, dar contribuie și la obținerea unor rezultate mai precise și de încredere în diagnosticarea imagistică, demonstrând astfel importanța preprocesării în obținerea unor modele eficiente de învățare profundă.

### 2.2.2 Prezentarea modelului ResNet50

Modelul ResNet50 este o arhitectură de rețea neuronală convoluțională (CNN) care utilizează straturi reziduale pentru a facilita antrenarea rețelelor adânci. Pre-antrenat pe setul de date ImageNet, acesta este capabil să învețe caracteristici vizuale avansate, care pot fi transferate către alte domenii, precum analiza imaginilor medicale. În acest studiu, ResNet50 este folosit pentru clasificarea imaginilor radiologice, cu scopul de a identifica prezența pneumoniei.

### 2.2.3 Configurarea ResNet50

Codul utilizează următorii pași pentru configurarea modelului ResNet50:

#### 1. Inițializare și încărcare a greutăților pre-antrenate

Modelul ResNet50 este inițializat cu greutăți pre-antrenate pe ImageNet și configurat să excludă stratul final specific clasificării pentru ImageNet (`include_top=False`). Inputul este definit pentru imagini de dimensiune (224, 224, 3).

#### 2. Congelarea straturilor pre-antrenate

Pentru a păstra caracteristicile învățate în timpul pre-antrenării, toate straturile ResNet50 sunt “înghețate”, ceea ce înseamnă că nu vor fi actualizate în timpul antrenării.

#### 3. Adăugarea unui capăt personalizat (custom head)

Pe baza caracteristicilor extrase de ResNet50, se adaugă un strat Flatten pentru a reduce dimensiunea datelor, urmat de un strat dens (Dense) cu funcția de activare softmax. Acesta este responsabil pentru clasificarea finală între cele două clase: fără pneumonie și pneumonie.

#### 4. Compilarea modelului

Modelul este compilat folosind funcția de pierdere `sparse_categorical_crossentropy`, optimizatorul adam, și metrici de evaluare precum accuracy.

### 2.2.4 Antrenarea și evaluarea modelului

După configurare, modelul este antrenat pe setul de date de imagini radiologice preprocesate. Datele sunt împărțite în trei subseturi: antrenare, validare și testare, iar antrenarea se face în batch-uri mici de dimensiune 16, pe parcursul a 5 epoci.

## 2.3 Configurația Experimentelor

În cadrul experimentelor realizate pentru evaluarea performanței modelului, s-au implementat mai multe configurări esențiale pentru a asigura validitatea și relevanța rezultatelor obținute. Mai jos sunt prezentate principalele aspecte ale configurației experimentale.

### 2.3.1 Împărțirea Setului de Date

Un aspect crucial în procesul de antrenare a modelelor de învățare profundă este împărțirea setului de date în sub-seturi destinate pentru antrenare, validare și testare. Pentru această investiție, s-a optat pentru o distribuție de 70%-15%-15%. Astfel, 70% din date au fost utilizate pentru antrenarea modelului, 15% pentru validarea acestuia în timpul antrenării (pentru a preveni supraînvățarea), iar 15% pentru testarea finală a performanțelor modelului. Această schemă de împărțire permite o evaluare echilibrată și reprezintă un standard acceptat în domeniu.

### 2.3.2 Metrice de Evaluare

Pentru a evalua eficacitatea modelului, au fost selectați următorii metrice de evaluare:

- **AUC-ROC:** Area Under the Receiver Operating Characteristic Curve (AUC-ROC) reprezintă o metrică fundamentală pentru evaluarea performanțelor modelelor de clasificare, fie că este vorba de clasificare binară sau multiclase. Această metrică măsoară capacitatea modelului de a distinge corect între clasele pozitive și negative și oferă o imagine globală asupra eficienței prin evaluarea tuturor pragurilor de clasificare posibile. Un AUC de 0,5 sugerează o capacitate de clasificare aleatorie, în timp ce un AUC de 1,0 semnalează o performanță perfectă.
- **Sensibilitate și Specificitate:** Aceste metrice sunt esențiale în evaluarea performanțelor modelului în cadrul diagnosticării medicinale. Sensibilitatea, cunoscută și sub denumirea de rată de adevărat pozitiv (TPR), măsoară proporția cazurilor pozitive corect identificate de model, în timp ce specificitatea (TNR) reflectă proporția cazurilor negative corect clasificate. Aceste două metrice sunt cruciale în contextul diagnosticării, deoarece pot influența deciziile clinice.
- **Dice Score:** Pentru evaluarea sarcinilor de segmentare, Dice Score reprezintă o metrică de comparare între seturile de date a rezultatelor modelului și etichetele de referință. Cunoscut și ca F1 Score, aceasta măsoară similaritatea dintre două seturi, având valori cuprinse între 0 (fără suprapunere) și 1 (suprapunere perfectă). Dice Score este utilizat pe scară largă în aplicarea segmentării imaginilor medicale, oferind o imagine clară asupra preciziei modelului în identificarea structurilor de interes în imagini.

Această configurație a experimentelor, inclusiv împărțirea datelor și metricele de evaluare selectate, este esențială pentru asigurarea unei analize riguroase a performanțelor modelului și pentru validarea rezultatelor obținute în cadrul studiului.

## 2.4 Validarea Rezultatelor

### 2.4.1 Strategii de Validare

Pentru a evalua performanța modelelor de învățare profundă și a asigura o validare robustă a rezultatelor, este esențial să se utilizeze strategii corespunzătoare de validare. O metodă eficientă utilizată frecvent în acest scop este validarea încrucișată k-fold. Această tehnică implică împărțirea setului de date în k subgrupuri (folds), de obicei  $k=5$  sau  $k=10$ , unde fiecare fold servește alternativ ca set de testare, în timp ce celelalte  $k-1$  folduri sunt utilizate pentru antrenare. Această abordare ajută la reducerea variabilității rezultatelor și oferă o estimare mai stabilă a performanței modelului pe datele noi.

Prin intermediul validării încrucișate, se poate obține o evaluare mai fiabilă, deoarece permite modelului să fie testat pe toate datele disponibile, asigurând că rezultatele nu sunt influențate de un set de date specific. Aceasta crește și șansele de generalizare a modelului, având în vedere diversitatea datelor de antrenare. Validarea încrucișată k-fold este adoptată pe scară largă în literatura de specialitate și este considerată o practică standard pentru evaluarea performanței în analiza datelor.

Pe lângă validarea încrucișată, este important să se utilizeze un set de test complet separat pentru evaluarea generalizării modelului. Acesta ar trebui să fie exclus din procesul de antrenare și validare, oferind o imagine clară asupra capacității modelului de a se adapta la date necunoscute. Această metodă asigură că rezultatele obținute reflectă cu adevărat eficiența modelului în medii reale de utilizare.

### 2.4.2 Rezultate Intermediare

Analizând rezultatele intermediare obținute în urma experimentele efectuate, se pot observa performanțe promițătoare în diagnosticarea diferitelor patologii. De exemplu, modelul ResNet50 a obținut un AUC (Area Under the Curve) de 0.75 atunci când a fost testat pe setul de date ChestX-ray14, special pentru diagnosticul pneumoniei. Aceasta demonstrează capacitatea modelului de a distinge între imagini radiografice sănătoase și cele care prezintă semne de pneumonie.

