

Capitolul 3. Related work

3.1 Introducere

Clasificarea imaginilor medicale utilizând învățarea profundă a fost un subiect de cercetare intensă, mai ales în domeniul radiologiei. Modelele de rețele neuronale convoluționale (CNN), precum ResNet, VGG, și DenseNet, au fost utilizate pe scară largă datorită capacității lor de a învăța caracteristici complexe din date vizuale. În această secțiune, se prezintă lucrările relevante din literatură, comparând abordarea propusă cu metodele existente, evidențiind similitudinile, diferențele și zonele unde se pot obține rezultate mai bune.

3.2 Abordări din literatura de specialitate

3.2.1 Modelul CheXNet

CheXNet este un model bazat pe DenseNet-121, pre-antrenat pe ImageNet și adaptat pentru clasificarea afecțiunilor pulmonare din setul de date ChestX-ray14. Acesta a atins performanțe remarcabile în detectarea pneumoniei, raportând o acuratețe de 76% și o valoare AUC de 0.78 pentru clasificarea binaryă (pneumonie vs. fără pneumonie). Spre deosebire de abordarea propusă, CheXNet se concentrează exclusiv pe optimizarea performanței prin fine-tuning complet al modelului.

3.2.2 Utilizarea ResNet pentru imagini medicale

Studiile anterioare au arătat că ResNet50 oferă performanțe competitive în clasificarea imaginilor radiologice, cu o rată de acuratețe medie de 92-95% pe diverse subseturi din ChestX-ray14. ResNet este preferat datorită straturilor reziduale, care facilitează antrenarea unor rețele mai adânci. În comparație cu DenseNet, ResNet tinde să fie mai robust la seturi de date reduse, dar necesită o selecție atentă a hiperparametrilor.

3.2.3 Transferul de învățare cu ImageNet

Transferul de învățare este o tehnică obișnuită pentru clasificarea imaginilor medicale, reducând necesitatea antrenării de la zero. Modelele precum VGG16, Inception, și ResNet sunt adesea pre-antrenate pe ImageNet, iar straturile lor finale sunt personalizate pentru problemele medicale. Abordarea propusă utilizează un mecanism similar, dar păstrează straturile ResNet50 înghețate, ceea ce simplifică procesul de antrenare și reduce timpul necesar.

3.2.4 Diferențe și asemănări

| Aspect | Abordarea propusă | Literatura existentă |
|---------------------|--------------------------------------|------------------------------------|
| Model utilizat | ResNet50 pre-antrenat | DenseNet-121, ResNet, VGG16 |
| Fine-tuning | Straturile ResNet înghețate | Fine-tuning complet |
| Set de date | Subset de 2000 imagini ChestX-ray14 | Întreg setul ChestX-ray14 |
| Metrici raportate | Acuratețe: 98%, Val_loss scăzut | Acuratețe: ~92-95% |
| Efort computațional | Reducere prin înghețarea straturilor | Mai mare datorită fine-tuning-ului |

3.3 Zone de îmbunătățire

Abordarea propusă demonstrează performanțe excelente în termeni de acuratețe (98%) și pierdere redusă (val_loss de 0.1824 după 5 epoci), ceea ce este comparabil sau superior multor studii anterioare. Zonele unde se așteaptă rezultate similare sau mai bune includ:

1. Acuratețea clasificării

Cu o acuratețe de 98% pe setul de testare, modelul nostru depășește sau este comparabil cu cele mai bune rezultate raportate de alte modele CNN pe subseturi similare.

2. Eficiența computațională

Congelarea straturilor ResNet50 reduce timpul de antrenare, ceea ce face abordarea noastră mai practică pentru aplicații clinice rapide.

3. Generalizare

Valoarea ridicată a acurateții pe setul de validare (98.67%) sugerează o bună generalizare, în ciuda utilizării unui subset mai mic de date.

3.4 Provocări și limite

Totuși, abordarea propusă este limitată de lipsa unui fine-tuning complet al ResNet50, ceea ce ar putea îmbunătăți performanța pe seturi de date mai mari. În plus, un subset mai mare de date ar putea oferi o evaluare mai robustă a modelului și ar reduce riscul de overfitting.

Această comparație evidențiază potențialul ResNet50 ca soluție eficientă și performantă pentru clasificarea imaginilor radiologice, oferind rezultate remarcabile chiar și cu o configurare relativ simplă.